

**HỆ THỐNG TÌM KIẾM THÔNG TIN LOÀI RẮN
THEO MÔ TẢ NGÔN NGỮ TỰ NHIÊN
SỬ DỤNG MÔ HÌNH HỌC SÂU**

Phạm Thị Hồng Chúc

Đại Nam University

Hà Nội, Việt Nam

MỤC LỤC

I. Đặt vấn đề	1
II. Các nghiên cứu liên quan	1
III. Thu thập và chuẩn bị bộ dữ liệu	2
III-A. Thông số kỹ thuật	2
III-B. Đa dạng dữ liệu	2
III-C. Chuẩn bị dữ liệu văn bản	2
III-D. Bộ kiểm thử độc lập (60 ảnh)	2
IV. Hệ thống nhận dạng hai tầng đề xuất	2
IV-A. Cơ chế Fallback: SigLIP Retrieval-Augmented Classification	2
IV-B. Lọc thô qua SigLIP	2
IV-C. Phân loại chuyên sâu qua ConvNeXt_Tiny	4
IV-D. Cơ chế loại bỏ ảnh ngoài phân phối (SigLIP OOD Gate)	4
IV-E. Bảng tổng hợp siêu tham số hệ thống	5
V. Đánh giá thực nghiệm	5
V-A. Thiết lập và tiêu chí đánh giá	5
V-B. So sánh hiệu suất với các baseline	5
V-C. Đánh giá trên 3 bộ kiểm thử độc lập	5
V-D. Phân tích không gian đặc trưng	6
VI. Kiến trúc luồng hệ thống	6
VII. Kết luận	6
Tài liệu tham khảo	6

Danh mục hình ảnh

Hình 1. Sơ đồ cơ chế Fallback — ConvNeXt kích hoạt SigLIP kNN Voting	3
Hình 2. Biểu đồ phân bố số lượng ảnh theo loài rắn	3
Hình 3. Không gian vector SigLIP — t-SNE 2D	3
Hình 4. Heatmap cosine similarity giữa các loài (SigLIP Embeddings)	3
Hình 5. Kết quả truy vấn bằng ảnh (Image Query)	4
Hình 6. Kết quả tìm kiếm bằng văn bản (Text Query)	4
Hình 7. Ma trận nhầm lẫn ConvNeXt_Tiny (Confusion Matrix)	4
Hình 8. Báo cáo phân loại chi tiết theo loài	4
Hình 9. Không gian đặc trưng t-SNE — ConvNeXt_Tiny	4
Hình 10. So sánh trực quan P, R, F1 trên sáu phương pháp	5
Hình 11. So sánh đa tiêu chí để chọn kiến trúc hai tầng	5
Hình 12. Đánh giá theo năm tiêu chí triển khai lâm sàng	5
Hình 13. Kiến trúc luồng tìm kiếm bằng văn bản	6
Hình 14. Kiến trúc luồng tìm kiếm bằng hình ảnh	6

Danh mục bảng

Bảng I. Thống kê bộ dữ liệu	2
Bảng II. Ba bộ kiểm thử độc lập (60 ảnh)	3
Bảng III. Độ tương đồng nội lớp SigLIP Embeddings	4
Bảng IV. Siêu tham số hệ thống	5
Bảng V. Kết quả OOD Gate trên 60 ảnh held-out	6

Hệ Thống Tìm Kiếm Thông Tin Loài Rắn Theo Mô Tả Ngôn Ngữ Tự Nhiên Sử Dụng Mô Hình Học Sâu

Phạm Thị Hồng Chúc
Đại Nam University
Hà Nội, Việt Nam

Tóm tắt nội dung—Rắn độc cắn là một vấn đề sức khỏe cộng đồng nghiêm trọng ở Việt Nam, gây ra nhiều thương vong và tử vong mỗi năm. Việc xác định nhanh chóng và chính xác loài rắn là yếu tố quyết định để lựa chọn đúng huyết thanh kháng nọc trong thời gian vàng điều trị. Tuy nhiên, việc phân biệt bằng mắt thường rất khó do sự tương đồng hình thái cao giữa các loài. Bài báo đề xuất hệ thống nhận dạng tự động hai tầng kết hợp SigLIP cho truy xuất đa phương thức văn bản-hình ảnh và ConvNeXt-Tiny cho phân loại chuyên sâu, tích hợp SigLIP OOD Gate và cơ chế Fallback k-NN Voting hai quy tắc. Chúng tôi giới thiệu bộ dữ liệu cân bằng mới gồm 1.691 ảnh thuộc 10 loài rắn nguy hiểm nhất Việt Nam. Hệ thống đạt điểm F1 97,12% trên tập validation nội bộ, 75% trên tập held-out iNaturalist và từ chối 100% trong 26 ảnh không phải rắn.

Index Terms—nhận dạng loài rắn, học sâu, SigLIP, ConvNeXt, phát hiện OOD, truy xuất đa phương thức, ngôn ngữ tự nhiên

I. ĐẶT VẤN ĐỀ

Tai nạn do rắn độc cắn hiện là một trong những bệnh nhiệt đới bị lãng quên, gây thách thức lớn cho hệ thống y tế công cộng, đặc biệt tại các quốc gia có tỷ lệ lao động nông nghiệp cao như Việt Nam. Đặc trưng khí hậu nhiệt đới gió mùa tạo điều kiện sinh thái lý tưởng cho sự phân bố của nhiều họ rắn độc có độc lực cao, tiêu biểu là họ Rắn hổ bao gồm các giống rắn hổ mang, cạp nong, cạp nia và họ Rắn lục như rắn lục đuôi đỏ. Thống kê dịch tễ học cho thấy, hàng năm các cơ sở y tế tiếp nhận số lượng lớn ca nhiễm độc rắn; trong đó, hiệu quả can thiệp lâm sàng phụ thuộc tuyến tính vào khả năng định danh chính xác loài trong “cửa sổ thời gian vàng” nhằm chỉ định kháng huyết thanh đặc hiệu.

Tuy nhiên, quy trình chẩn đoán hiện nay vẫn phụ thuộc phần lớn vào phương pháp quan sát hình thái học trực quan, dẫn đến xác suất sai sót cao. Nguyên nhân xuất phát từ sự tương đồng kiểu hình và hiện tượng bắt chước hình thái tinh vi giữa các loài rắn độc và rắn lành thông qua cấu trúc vảy, dạng hình học của đầu hoặc sắc tố da. Thách thức này càng nghiêm trọng hơn trong các tình huống thực tế khi dữ liệu hình ảnh thu thập được bị giới hạn bởi điều kiện ánh sáng yếu, nhiễu chuyển động do tâm lý hoảng loạn của nạn nhân, hoặc đối tượng bị che khuất một phần.

Để giải quyết các hạn chế trên, việc ứng dụng các kỹ thuật học sâu trong thị giác máy tính và xử lý thông tin đa phương thức mở ra một hướng tiếp cận khả thi và hiệu quả. Nghiên cứu này đề xuất một giải pháp tự động nhận diện các loài rắn

độc dựa trên sự kết hợp giữa đặc trưng thị giác và thông tin ngữ nghĩa từ mô tả của người dùng. Hệ thống không chỉ hỗ trợ rút ngắn thời gian chẩn đoán lâm sàng mà còn nâng cao độ chính xác trong các điều kiện thu thập dữ liệu phức tạp của môi trường thực tế.

Bài báo đề xuất hệ thống nhận dạng loài rắn tự động hướng đến ứng dụng trong y tế, với ba đóng góp cốt lõi sau đây:

- Xây dựng bộ dữ liệu chuẩn hóa và cân bằng:** Giới thiệu một bộ dữ liệu hình ảnh mới bao gồm 1.691 ảnh thuộc 10 loài rắn phổ biến nhất tại Việt Nam. Bộ dữ liệu được thiết kế với độ cân bằng cao khi độ lệch giữa các lớp đối tượng tối đa chỉ đạt 14 hình ảnh, giúp hạn chế hiện tượng thiên vị lớp trong quá trình huấn luyện mô hình.
- Đề xuất kiến trúc lai hai tầng tiên tiến:** Thiết kế giải pháp kết hợp giữa mô hình ngôn ngữ-hình ảnh đa phương thức cho tác vụ truy xuất và mạng nơ-ron tích chập hiện đại đóng vai trò phân loại chuyên sâu. Kiến trúc này được tích hợp cơ chế dự phòng dựa trên thuật toán bầu chọn theo láng giềng gần nhất song quy tắc, giúp tối ưu hóa độ chính xác và tính linh hoạt của hệ thống.
- Tích hợp cổng kiểm soát dữ liệu ngoại biên:** Phát triển cơ chế lọc dựa trên mô hình đa phương thức nhằm phát hiện và từ chối hoàn toàn 100% các hình ảnh không thuộc đối tượng nghiên cứu (hình ảnh không phải loài rắn). Đóng góp này đóng vai trò quyết định trong việc đảm bảo tính an toàn và độ tin cậy khi triển khai hệ thống vào thực tế lâm sàng.

II. CÁC NGHIÊN CỨU LIÊN QUAN

Nhận dạng loài sinh vật từ hình ảnh là một trong những bài toán quan trọng của thị giác máy tính. Nhiều nghiên cứu đã áp dụng các kiến trúc học sâu như ResNet [9], EfficientNet, Vision Transformer (ViT) [5] và ConvNeXt [3] để thực hiện phân loại ảnh động vật, thực vật và côn trùng. Các mô hình này có khả năng học đặc trưng hình thái như màu sắc, hoa văn và cấu trúc cơ thể từ dữ liệu hình ảnh với độ chính xác cao. Trong đó, ConvNeXt kế thừa nhiều cải tiến từ Vision Transformer nhưng vẫn duy trì cấu trúc CNN truyền thống, cho hiệu năng cạnh tranh trên các tác vụ phân loại ảnh quy mô lớn.

Bên cạnh dữ liệu hình ảnh, mô tả văn bản do người dùng cung cấp cũng chứa nhiều thông tin hữu ích cho việc nhận

dạng loài. Trong lĩnh vực xử lý ngôn ngữ tự nhiên, các mô hình tiền huấn luyện như BERT và Sentence-BERT [13] đã được sử dụng rộng rãi để biểu diễn câu dưới dạng vector ngữ nghĩa phục vụ các bài toán truy hồi thông tin và tìm kiếm theo ngữ nghĩa. Đối với tiếng Việt, PhoBERT là một trong những mô hình ngôn ngữ tiền huấn luyện tiêu biểu, cho khả năng nắm bắt ngữ cảnh và ý nghĩa từ vựng tốt hơn các phương pháp dựa trên từ khóa truyền thống. Nhiều nghiên cứu đã phát triển các biến thể Sentence-PhoBERT nhằm ánh xạ câu tiếng Việt vào không gian vector ngữ nghĩa phục vụ bài toán so khớp và truy xuất thông tin.

Những năm gần đây, các mô hình đa phương thức đã mở ra hướng tiếp cận mới cho việc kết hợp dữ liệu hình ảnh và văn bản. Tiêu biểu là CLIP [8], mô hình học tương phản giúp ánh xạ ảnh và văn bản vào cùng một không gian biểu diễn, cho phép thực hiện tìm kiếm và so khớp đa phương thức. Trên nền tảng đó, SigLIP [4] được đề xuất nhằm thay thế cơ chế softmax toàn cục bằng sigmoid loss theo từng cặp ảnh-văn bản, giúp tối ưu ổn định hơn trên các tập dữ liệu chuyên biệt. Các mô hình này cho phép tận dụng đồng thời đặc trưng thị giác và ngữ nghĩa văn bản, phù hợp với các hệ thống nhận dạng dựa trên cả hình ảnh và mô tả từ người dùng.

III. THU THẬP VÀ CHUẨN BỊ BỘ DỮ LIỆU

A. Thông số kỹ thuật

Chúng tôi thu thập bộ dữ liệu chuyên biệt gồm **1.691 hình ảnh** thuộc 10 loài rắn phổ biến tại Việt Nam với cân bằng nghiêm ngặt giữa các lớp (Bảng I).

Bảng I: Thống kê bộ dữ liệu

Chỉ số	Giá trị
Tổng số hình ảnh	1.691
Số lượng loài	10
Loài nhiều nhất	Rắn lục ròi & Rắn biển bụng vàng (175 ảnh)
Loài ít nhất	Rắn lục núi (161 ảnh)
Chênh lệch tối đa	14 ảnh
Tập huấn luyện (80%)	1.352 ảnh
Tập kiểm tra (20%)	339 ảnh

10 loài mục tiêu: *Rắn bay sọc vàng*, *Rắn biển bụng vàng*, *Rắn cạp nia*, *Rắn cạp nong*, *Rắn chàm quạp*, *Rắn khiếm (rắn cầu vồng)*, *Rắn lục đuôi đỏ*, *Rắn lục núi*, *Rắn lục ròi (rắn lục Vogel)* và *Rắn hoa cỏ cổ đỏ*.

B. Đa dạng dữ liệu

Hình ảnh được thu thập từ nhiều môi trường: tự nhiên, khu dân cư và hồ sơ bệnh án lâm sàng để tối đa hóa tính thực tế khi triển khai. Bộ dữ liệu thể hiện biến động lớn về nền, ánh sáng, che khuất và tư thế rắn. Tất cả hình ảnh được chuẩn hóa và thay đổi kích thước về 224×224 pixel.

C. Chuẩn bị dữ liệu văn bản

Để hỗ trợ tinh chỉnh SigLIP, chúng tôi xây dựng **903 câu mô tả tiếng Việt** (30–40 câu/loài) dưới dạng người quan sát mô tả đặc điểm hình thái. Ngoài ra, **330 bộ ba triplet** ($\mathbf{q}, \mathbf{p}, \mathbf{n}$) được tổ chức để học metric learning, trong đó $\mathbf{n}$ là mẫu âm khó từ loài có ngoại hình tương tự.

D. Bộ kiểm thử độc lập (60 ảnh)

Ngoài tập validation nội bộ, hệ thống được đánh giá trên 3 bộ kiểm thử độc lập phản ánh điều kiện triển khai thực tế (Bảng II):

IV. HỆ THỐNG NHẬN DẠNG HAI TẦNG ĐỀ XUẤT

Hệ thống gồm 4 thành phần thực thi tuần tự: **(1)** SigLIP OOD Gate, **(2)** Tầng 1 SigLIP retrieval, **(3)** Tầng 2 ConvNeXt-Tiny classification, **(4)** Fallback k-NN Voting hai quy tắc. Đầu vào có thể là ảnh hoặc mô tả văn bản tự do tiếng Việt.

A. Cơ chế Fallback: SigLIP Retrieval-Augmented Classification

Để tối ưu hóa hệ thống khi triển khai thực tế, cơ chế Fallback được thiết lập xử lý các trường hợp ảnh chất lượng thấp (mờ, thiếu sáng, góc chụp lạ) mà bộ phân loại đơn thuần khó xử lý chính xác.

Gọi $\mathbf{p}_{\text{conv}} \in \mathbb{R}^{10}$ là phân phối softmax ConvNeXt. Định nghĩa:

$$\text{top1} = \max_c p_{\text{conv}}(c), \quad (1)$$

$$\text{margin} = p_{\text{conv}}(c_{(1)}) - p_{\text{conv}}(c_{(2)}), \quad (2)$$

trong đó $c_{(1)}, c_{(2)}$ là lớp dự đoán cao nhất và nhì. Cơ chế fallback kích hoạt khi một trong hai quy tắc thỏa mãn:

R1 (Độ tin cậy thấp) $\text{top1} < \tau_c$ hoặc $\text{margin} < \tau_m$

ConvNeXt không đủ tự tin về top-1 hoặc không phân biệt rõ top-1 với top-2.

R2 (Giải quyết bất đồng) $\mathbf{p}_{\text{conv}} \neq \mathbf{p}_{\text{knn}}$ và $\text{top1} < \tau_{\text{trust}}$ và $\text{top1}_{\text{knn}} \geq \tau_{\text{knn}}$

ConvNeXt và SigLIP k-NN bất đồng trong khi SigLIP có đồng thuận mạnh từ láng giềng.

Khi fallback kích hoạt, thuật toán k-NN Voting có trọng số:

$$\text{score}(c) = \sum_{i \in \mathcal{N}(I), y_i = c} s_i, \quad p_{\text{knn}}(c) = \frac{\text{score}(c)}{\sum_{c'} \text{score}(c')}, \quad (3)$$

trong đó $\mathcal{N}(I)$ là $k=5$ ảnh gần nhất trong không gian SigLIP và $s_i = \mathbf{e}_i^\top \mathbf{e}_i$.

B. Lọc thô qua SigLIP

SigLIP nhận truy vấn tự do, trích xuất danh sách ảnh tương đồng nhất từ cơ sở dữ liệu 1.691 ảnh. Khác với CLIP dùng softmax loss, SigLIP dùng sigmoid loss theo cặp:

$$\mathcal{L}_{\text{sig}} = -\frac{1}{N^2} \sum_{i,j} \log \sigma(z_{ij} (2 \mathbf{1}[i=j] - 1)), \quad (4)$$


trong đó $z_{ij} = \tau \mathbf{e}_i^\top \mathbf{e}_j + b$, τ là nhiệt độ có thể học, b là bias có thể học.

Cấu hình tinh chỉnh: google/siglip-base-patch16-224; đóng băng toàn bộ, chỉ mở 2 lớp cuối của vision + text encoder; AdamW $\text{lr} = 2 \times 10^{-6}$, weight decay = 0,02; cosine warmup scheduler; early stopping patience 5; GPU NVIDIA T4 (Kaggle).

Hệ thống hỗ trợ **2 chế độ truy vấn**:

Bảng II: Ba bộ kiểm thử độc lập (60 ảnh)


Bộ test	N	Mô tả
test_new_snake	20	10 loài $\times$ 2 ảnh iNaturalist; ảnh thực tế chụp ngoài trời, khác phân phối tập huấn luyện
test_ood	26	Không có rắn: người (4), chó (3), mèo (4), lá cây (4), phong cảnh (2), đồ vật (5: dây điện, dây thùng, bình tưới, ô, táo), hoa (4)
test_other_species	14	Rắn ngoài 10 loài huấn luyện: rắn hổ mang chúa, rắn hổ mang một mắt kính, trăn gấm, trăn mốc, rắn liều xanh và 4 loài bổ sung
Tổng	60	




Hình 1: Sơ đồ luồng xử lý cơ chế Fallback — ConvNeXt độ tin cậy thấp kích hoạt SigLIP kNN Voting. Đường **đỏ**: R1 hoặc R2 kích hoạt siglip_knn. Đường **xanh**: trả về kết quả convnext trực tiếp.



Hình 3: Không gian vector SigLIP — t-SNE 2D. 10 cụm tách biệt rõ ràng xác nhận embedding đã học được đặc trưng phân biệt theo loài.



Hình 2: Biểu đồ phân bố số lượng ảnh theo loài rắn. Chênh lệch tối đa chỉ 14 ảnh xác nhận bộ dữ liệu gần như cân bằng hoàn hảo.



Hình 4: Heatmap cosine similarity giữa các loài (SigLIP Embeddings). Độ tương đồng cao giữa các loài cùng họ (ví dụ: Rắn cạp nia $\leftrightarrow$ Rắn cạp nong, $s = 0,81$) có căn cứ sinh học rõ ràng.

- 1) *Truy vấn bằng ảnh*: SigLIP mã hóa ảnh thành vector, quét 1.691 ảnh trả về Top-5 tương đồng nhất (Hình 5).
- 2) *Truy vấn bằng văn bản*: mã hóa câu mô tả tiếng Việt rồi tìm kiếm cosine similarity (Hình 6). Đây là khả năng mà CNN đơn thuần không thể thực hiện.

Phân tích độ tương đồng nội lớp được trình bày trong Bảng III:



Hình 5: Truy vấn bằng ảnh (Image Query): ảnh rắn bay sọc vàng trên tường gạch được mã hóa và khớp với cơ sở dữ liệu. Tất cả 5 ảnh trả về đều đúng loài.




Hình 6: Tìm kiếm bằng văn bản (Text Query): mô tả tiếng Việt tự do được mã hóa và khớp với index ảnh mà không cần ảnh tham chiếu.

C. Phân loại chuyên sâu qua ConvNeXt_Tiny

ConvNeXt_Tiny tiếp nhận ảnh truy vấn, trả về tên tiếng Việt và xác suất tin cậy (Confidence Score).

Cấu hình tinh chỉnh: đóng băng toàn bộ, chỉ mở head và 2 stage cuối; lr 2 nhóm (head: 5×10^{-4} , stage[-1]: 5×10^{-5}); label smoothing $\varepsilon = 0,1$; dropout $p = 0,3$; early stopping patience 5. Augmentation: RandomHorizontalFlip, RandomVerticalFlip, RandomRotation (20°), ColorJitter, RandomResizedCrop (224), GaussianBlur.




Hình 7: Ma trận nhầm lẫn ConvNeXt_Tiny trên tập validation 339 ảnh. Sai số tập trung chủ yếu giữa các loài rắn lục cùng họ — có căn cứ sinh học.

Bảng III: Độ tương đồng nội lớp SigLIP Embeddings

Loài	Sim.	Nhận xét
Rắn cạp nong	0.89	Cụm chặt nhất
Rắn lục đuôi đỏ	0.87	Tốt
Rắn cạp nia	0.86	Tốt
Rắn lục rôi	0.84	Tốt
Rắn biển bụng vàng	0.83	Tốt
Rắn bay sọc vàng	0.80	Cụm phân tán nhất

	precision	recall	f1-score	support
Rắn bay sọc vàng	1.00	1.00	1.00	34
Rắn biển bụng vàng	1.00	1.00	1.00	35
Rắn cạp nia	1.00	1.00	1.00	33
Rắn cạp nong	1.00	1.00	1.00	34
Rắn chàm quạp	0.97	1.00	0.99	35
Rắn hoa cỏ cổ đỏ	0.94	1.00	0.97	34
Rắn khiếm (rắn cầu vồng)	0.97	0.97	0.97	33
Rắn lục đuôi đỏ	0.97	0.97	0.97	34
Rắn lục núi	1.00	0.94	0.97	32
Rắn lục rôi (rắn lục Vogel)	1.00	0.97	0.99	35
accuracy			0.99	339
macro avg	0.99	0.98	0.99	339
weighted avg	0.99	0.99	0.99	339

Hình 8: Báo cáo phân loại chi tiết theo loài. Rắn lục núi có Recall thấp nhất (0,94); Rắn hoa cỏ cổ đỏ đạt Recall 1,00 nhưng Precision thấp nhất (0,94).



Hình 9: Không gian đặc trưng t-SNE — ConvNeXt_Tiny. 10 cụm tách biệt hoàn toàn với khoảng cách liên cụm lớn chứng minh model học được biểu diễn phân biệt cao. Chồng lấp nhỏ chỉ xảy ra giữa các loài rắn lục cùng họ.

D. Cơ chế loại bỏ ảnh ngoài phân phối (SigLIP OOD Gate)

Bộ phân loại softmax 10 lớp luôn ép kết quả thuộc 1 trong 10 loài, dẫn đến “sai một cách tự tin” khi đầu vào không phải rắn — đặc biệt nguy hiểm trong bối cảnh y tế. Chúng tôi đặt OOD Gate ở đầu pipeline:

$$s_{\max}(I) = \max_{i=1,\dots,1691} \mathbf{e}_I^\top \mathbf{e}_i, \quad \text{is_snake}(I) = [s_{\max}(I) \geq \tau_{\text{OOD}}]. \quad (5)$$

Khi is_snake = false, pipeline dừng ngay và trả về “Ảnh không thuộc 10 loài đã huấn luyện”; ConvNeXt không được gọi.

Hiệu chỉnh ngưỡng $\tau_{\text{OOD}} = 0,72$ dựa trên:

- *In-distribution* (1.691 ảnh training, leave-one-out): min = 0,702; $p_{50} = 0,927$; $p_{99} = 0,980$.
- *In-dist held-out* (test_new_snake): min = 0,753; $p_{50} = 0,872$.
- *OOD* (test_ood): min = 0,457; $p_{50} = 0,599$; max = 0,702.

Khe phân tách ($\Delta = 0,051$) đủ để chọn ngưỡng an toàn. Chỉ phí tính toán không đáng kể vì $s_{\max}$ đã tính sẵn cho k-NN voting.

E. Bảng tổng hợp siêu tham số hệ thống

Bảng IV: Siêu tham số hệ thống

Ký hiệu	Giá trị	Mô tả
τ_{OOD}	0,72	Ngưỡng OOD Gate (cosine sim tối thiểu)
τ_c	0,40	Ngưỡng ConvNeXt top-1 (R1)
τ_m	0,15	Ngưỡng margin top-1–top-2 (R1)
τ_{trust}	0,85	Ngưỡng “tự tin tuyệt đối” ConvNeXt (R2)
τ_{knn}	0,60	Ngưỡng SigLIP k-NN để override (R2)
k	5	Số láng giềng trong k-NN voting


V. ĐÁNH GIÁ THỰC NGHIỆM

A. Thiết lập và tiêu chí đánh giá

Bộ dữ liệu 1.691 ảnh được chia 80/20 stratified split (Huấn luyện: 1.352 | Validation: 339). Tối ưu hóa: AdamW, weight decay 10^{-2} , GPU NVIDIA T4. Chỉ số đánh giá: Precision (P), Recall (R), F1-score, Accuracy tổng thể.

Lưu ý quan trọng về ngữ cảnh đánh giá. F1 = 97,12% được đo trên tập validation nội bộ 339 ảnh (cùng phân phối huấn luyện). Con số 75% được đo trên `test_new_snake` 20 ảnh iNaturalist (khác phân phối). Khoảng cách 22 điểm phần trăm phản ánh hiện tượng domain shift — ảnh thực tế người dùng chụp ngoài trời khác biệt đáng kể so với ảnh dataset chuẩn. Hai con số báo cáo ở hai ngữ cảnh đánh giá khác nhau và cần được hiểu tách bạch.


B. So sánh hiệu suất với các baseline




Hình 10: So sánh trực quan ba chỉ số P, R, F1 trên sáu phương pháp. Hệ thống đề xuất (SigLIP + ConvNeXt) vượt trội tất cả baseline với biên độ đáng kể.

C. Đánh giá trên 3 bộ kiểm thử độc lập

So sánh đa tiêu chí: cơ sở để chọn kiến trúc 2 tầng



Hình 11: So sánh đa tiêu chí để lựa chọn kiến trúc hai tầng. YOLO mạnh ở tốc độ và detection; CLIP mạnh ở zero-shot tổng quát; ConvNeXt mạnh ở classification thuần. Không model đơn lẻ nào đáp ứng toàn diện 5 tiêu chí triển khai lâm sàng.



Hình 12: Đánh giá theo năm tiêu chí triển khai lâm sàng: độ chính xác, hỗ trợ ngôn ngữ tự nhiên, khả năng từ chối OOD, diễn giải trực quan, và chi phí suy luận. Hệ thống đề xuất bao phủ rộng nhất.

Bảng V: Kết quả OOD Gate trên 60 ảnh held-out ($\tau_{\text{OOD}} = 0,72$)

Bộ xét nghiệm	Số lượng ảnh	Cổng vượt qua	Từ
test_new_snake	20	20 (100%)	0 (
test_ood	26	0 (0%)	26 (
test_other_species	14	10 (71,4%)	4 (2

test_new_snake: Ensemble đạt 75% (15/20), tăng 10 điểm so với ConvNeXt đơn lẻ (65%). R1 kích hoạt 5 ảnh, R2 kích hoạt 2 ảnh.

test_ood: OOD Gate đạt từ chối hoàn hảo (26/26, 0 false positive). Không có ảnh không phải rắn nào bị phân loại vào loài huấn luyện.


test_other_species: 4 ảnh bị từ chối đúng ($s_{\text{max}} < 0,72$). Trong 10 ảnh lọt gate: 8 ảnh kích hoạt Fallback kèm cảnh báo độ tin cậy thấp; chỉ 2 ảnh được phân loại “tự tin” vào loài gần nhất. Đây là hành vi an toàn mong đợi.

D. Phân tích không gian đặc trưng


t-SNE ConvNeXt_Tiny cho thấy 10 cụm tách biệt hoàn toàn với khoảng cách liên cụm lớn và phân tán nội cụm hẹp — chứng minh model học được biểu diễn phân biệt thật sự. Chồng lấp nhỏ chỉ xảy ra giữa các loài rắn lục cùng họ, có căn cứ sinh học rõ ràng và nhất quán với phân tích heatmap SigLIP (Hình 4).

VI. KIẾN TRÚC LUỒNG HỆ THỐNG

Hệ thống được thiết kế theo hai luồng xử lý độc lập tương ứng với hai chế độ truy vấn: tìm kiếm bằng mô tả văn bản và tìm kiếm bằng hình ảnh. Mỗi luồng được tối ưu riêng biệt nhằm đảm bảo hiệu năng và độ chính xác cao nhất cho từng loại đầu vào.



Hình 13: Kiến trúc hệ thống — Luồng tìm kiếm bằng mô tả văn bản (Text Query). Pipeline đơn nhánh: SigLIP text encoder tạo vector 768-D, tính cosine similarity với 1.691 image embeddings, trả về Top-K ảnh khớp kèm tên loài và score.



Hình 14: Kiến trúc hệ thống — Luồng tìm kiếm bằng hình ảnh (Image Query). Pipeline hai nhánh: Nhánh 1 gồm SigLIP OOD Gate + ConvNeXt-Tiny phân loại chính; Nhánh 2 là SigLIP k-NN Voting fallback khi nhánh 1 không chắc chắn.

VII. KẾT LUẬN

Bài báo trình bày hệ thống hai tầng SigLIP + ConvNeXt nhận dạng 10 loài rắn nguy hiểm tại Việt Nam, tích hợp OOD Gate và Fallback k-NN Voting hai quy tắc. Hệ thống đạt F1 = 97,12% trên validation nội bộ, 75% trên held-out iNaturalist, và từ chối 100% ảnh không phải rắn.

Hạn chế cần thừa nhận: tập held-out chỉ 20 ảnh (khoảng tin cậy rộng); domain shift 22 điểm giữa ảnh chuẩn và ảnh thực tế vẫn tồn tại; một số loài rắn ngoài 10 lớp huấn luyện vẫn lọt OOD Gate.

Hướng phát triển: (1) Bổ sung ảnh iNaturalist vào training để giảm domain shift; (2) mở rộng thêm loài rắn Việt Nam; (3) tích hợp outlier exposure để cải thiện xử lý loài ngoài vocabulary; (4) triển khai ứng dụng di động tích hợp hướng dẫn sơ cứu lâm sàng.

TÀI LIỆU

- [1] H.-G. Doan và cộng sự, “Xác định loài rắn hạt mịn bằng mạng tích chập sâu,” *Tạp chí Tin học Sinh thái*, 2022.
- [2] A. Joly và cộng sự, “LifeCLEF 2024 Teaser: Challenges on the Identification and Prediction of Biodiversity,” trong *Proc. ECIR*, 2024.
- [3] Z. Liu và cộng sự, “A ConvNet for the 2020s,” trong *Proc. IEEE/CVF CVPR*, tr. 11976–11986, 2022.
- [4] X. Zhai và cộng sự, “Sigmoid Loss for Language Image Pre-Training,” *arXiv*:2303.15343, 2023.
- [5] A. Dosovitskiy và cộng sự, “An Image is Worth 16×16 Words,” trong *Proc. ICLR*, 2021.
- [6] I. Loshchilov và F. Hutter, “Decoupled Weight Decay Regularization,” trong *Proc. ICLR*, 2019.
- [7] G. Jocher, A. Chaurasia, và J. Qiu, “Ultralytics YOLOv8,” 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [8] A. Radford và cộng sự, “Learning Transferable Visual Models from Natural Language Supervision (CLIP),” trong *Proc. ICML*, tr. 8748–8763, 2021.
- [9] K. He, X. Zhang, S. Ren, và J. Sun, “Deep Residual Learning for Image Recognition,” trong *Proc. IEEE/CVF CVPR*, tr. 770–778, 2016.
- [10] G. Jocher và J. Qiu, “Ultralytics YOLO11,” 2024. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [11] L. van der Maaten và G. Hinton, “Visualizing Data using t-SNE,” *Journal of Machine Learning Research*, tập 9, số 11, 2008.
- [12] A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” trong *Advances in Neural Information Processing Systems*, 2019.
- [13] T. Wolf và cộng sự, “Transformers: State-of-the-Art Natural Language Processing,” trong *Proc. EMNLP: System Demonstrations*, 2020.